

逆関数法の実現に向けた関数近似手法の検討

Function Approximation Methods for the Inverse Transform Sampling

Tetsuo Kurosawa, Kensuke Ishitani, Naoki Oshio,
Aoi Samukawa, Rentaro Ueyama

Tokyo Metropolitan University

目次

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

目次

はじめに

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

はじめに～発表内容～

本講演では,

- 任意の確率分布に対して逆関数法を用いた乱数生成を実現することを念頭に置き, 逆関数法に必要な累積分布関数の逆関数¹の近似モデルを構成する手法を紹介する.
- 近似モデルを準モンテカルロ法へ適用した結果を報告する.

¹以下, 累積分布関数を「CDF」, その逆関数を「逆 CDF」と略記する

はじめに～乱数生成～

- **乱数生成**は、現代科学の様々な場面で用いられる基盤技術である。
- 特に、大量の乱数を使って数値的に積分値を求める手法は**モンテカルロ法**と呼ばれ、様々な分野の数値シミュレーションに用いられる。

金融: 資産の価格評価, リスク計算におけるモンテカルロ法

物理学: 分子動力学

機械学習: 重み行列の初期化, データ生成

- 乱数生成手法の研究対象は、**一様乱数の生成手法**と**一般の乱数の生成手法**に分かれる。

一様乱数: 代数学的な手法で擬似乱数列や準乱数列の生成規則を研究

一般の乱数: (一様乱数を所与として) **所望の分布に従う乱数を作る手法**を研究

← 今回扱うのはこちら

はじめに～所望の確率分布に従う乱数生成～

基本手順:

- まず独立な一様乱数の組 $U_1, \dots, U_s$ を生成し, 所望の分布に従う乱数 $X = g(U_1, \dots, U_s)$ に変換する²

汎用的な変換法の二大手法:

- **逆関数法:** 一様乱数を累積分布関数の逆関数に通す決定論的な手法
← 今回扱うのはこちら: 逆関数法のみを用いて任意の分布の乱数を生成したい
- 棄却法: 確率的に一様乱数を「棄却」するアルゴリズム

²より形式的には, ある確率変数 X について乱数生成可能であるとは, 「有限個の独立な一様乱数 $U_1, \dots, U_s$ に対して, ある関数 $g: [0, 1]^s \rightarrow \mathbb{R}$ が存在して $X = g(U_1, \dots, U_s)$ を満たす」ことをいう

導入

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

Theorem

U を一様分布 $U(0,1)$ に従う確率変数とし、 $F_X(x)$ を確率変数 X の CDF とする。このとき、確率変数 $F_X^{-1}(U)$ の CDF は $F_X(x)$ である、すなわち X と同じ分布に従う。

乱数生成への応用 (1 変数の場合)

上記の定理を用いると、以下のように確率変数 X の乱数を生成できる。

- まず一様乱数 $U = u$ を生成する。³
- X の CDF F_X の逆関数 F_X^{-1} を使って、 $x = F_X^{-1}(u)$ を計算する。
- 上記の定理より、 x は F_X に従う乱数となっている。

このようにして所望の分布の乱数を得る手法を**逆関数法**という。

³擬似乱数ならメルセンヌツイスターなど、準乱数なら Sobol' 列などを使って

s 変数の逆関数法

$(F_{X_1}, \dots, F_{X_s})$ を CDF にもつ s 個の確率変数の組 $(X_1, \dots, X_s)$ の乱数も、条件付き CDF を逐次用いることで以下のように生成できる.


- まず独立な一様乱数の組 $(U_1, \dots, U_s) = (u_1, \dots, u_s)$ を生成する.
- $F_{X_1}^{-1}(u_1)$ は X_1 の乱数であり, これを x_1 とする.
- 条件付き CDF $F_{X_2|X_1=x_1}$ に対し, その逆関数 $F_{X_2|X_1=x_1}^{-1}(u_2)$ は, $X_1 = x_1$ を得られた条件下での X_2 の乱数であり, これを x_2 とする.
- これを s 回繰り返すと, s 個の乱数の組 $(X_1, \dots, X_s) = (x_1, \dots, x_s)$ が得られる.
(ただし, $x_{i+1} = F_{X_{i+1}|X_1=x_1, \dots, X_i=x_i}^{-1}(u_{i+1})$)

導入～逆関数法～

s 変数の逆関数法

$(X, Y, Z) \sim F_{X,Y,Z}$
Uniform random
numbers

Realization of
 (X, Y, Z)



導入～逆関数法の特徴～

【利点】

- 準モンテカルロ法 (QMC) との親和性が高い⁴
- 分散減少法と相性が良い
- コピュラの乱数生成に使われる

【問題点】

- 逆 CDF を解析的に求められる分布は限られている
(e.g. 指数分布, コーシー分布, etc)
- 解析的に求められない場合, Newton 法等の求根アルゴリズムに頼る必要がある
→ 計算, 実行時間が膨大

本研究ではこの点に着目し, 高精度かつ高速な逆 CDF の近似手法を確立することを考える.

⁴棄却法は準乱数を確率的に捨てるため, 準乱数の規則的な構造を破壊してしまうのに対し, 逆関数法では決定論的な変換によって準乱数の構造を保存する

導入～逆 CDF の近似の先行研究～

標準正規分布の逆 CDF $\Phi^{-1}(u)$

Wichura (1988)

特殊な変数変換と minimax 有理関数近似を組み合わせた高精度モデル

$$\Phi^{-1}(u) \simeq \begin{cases} q \frac{((((((a_7x + a_6)x + a_5)x + a_4)x + a_3)x + a_2)x + a_1)x + a_0}{((((((b_7x + b_6)x + b_5)x + b_4)x + b_3)x + b_2)x + b_1)x + 1} & (|q| \leq 0.425) \\ \operatorname{sgn}(q) \frac{((((((c_7y + c_6)y + c_5)y + c_4)y + c_3)y + c_2)y + c_1)y + c_0}{((((((d_7y + d_6)y + d_5)y + d_4)y + d_3)y + d_2)y + d_1)y + 1} & (|q| > 0.425, r \leq 5) \\ \operatorname{sgn}(q) \frac{((((((e_7z + e_6)z + e_5)z + e_4)z + e_3)z + e_2)z + e_1)z + e_0}{((((((f_7z + f_6)z + f_5)z + f_4)z + f_3)z + f_2)z + f_1)z + 1} & (|q| > 0.425, r > 5) \end{cases}$$

ただし,

$$q := u - 0.5, \quad x := 0.425^2 - q^2$$

$$r := \sqrt{-\ln\{\min(u, 1-u)\}}, \quad y := r - 1.6, \quad z := r - 5$$

(各係数 $\{a_i\}_{0 \leq i \leq 7}, \{b_i\}_{1 \leq i \leq 7}, \{c_i\}_{0 \leq i \leq 7}, \{d_i\}_{1 \leq i \leq 7}, \{e_i\}_{0 \leq i \leq 7}, \{f_i\}_{1 \leq i \leq 7}$ の値は, 付録参照)

導入～逆 CDF の近似の先行研究～

標準正規分布の逆 CDF $\Phi^{-1}(u)$

Acklam[1]

独自の最良近似アルゴリズムで導いた有理関数近似モデル (旧業界標準)

$$\Phi^{-1}(u) \simeq \begin{cases} \frac{((((((a_1(u-0.5)^2+a_2)(u-0.5)^2+a_3)(u-0.5)^2+a_4)(u-0.5)^2+a_5)(u-0.5)^2+a_6)(u-0.5))}{((((((b_1(u-0.5)^2+b_2)(u-0.5)^2+b_3)(u-0.5)^2+b_4)(u-0.5)^2+b_5))(u-0.5)^2+1)} & (u_L \leq u \leq u_R) \\ \frac{((((((c_1 s(u)+c_2)s(u)+c_3)s(u)+c_4)s(u)+c_5)s(u)+c_6}{((d_1 s(u)+d_2)s(u)+d_3)s(u)+d_4)s(u)+1} & (u < u_L) \\ \frac{((((((c_1 t(u)+c_2)t(u)+c_3)t(u)+c_4)t(u)+c_5)t(u)+c_6}{((d_1 t(u)+d_2)t(u)+d_3)t(u)+d_4)t(u)+1} & (u_R < u) \end{cases}$$

ただし, $s(u) := \sqrt{-2 \ln u}$, $t(u) := \sqrt{-2 \ln(1-u)}$,

$u_L = 0.02425$, $u_R = 0.97575$

(各係数 $\{a_i\}_{1 \leq i \leq 6}$, $\{b_i\}_{1 \leq i \leq 5}$, $\{c_i\}_{1 \leq i \leq 6}$, $\{d_i\}_{1 \leq i \leq 4}$ の値は, 付録参照)

導入～逆 CDF の近似の先行研究～

任意の分布に対する逆 CDF の近似 (← 我々が目指していること)

- Derflinger et al.(2008)[2]:
ユーザーが与えた任意の密度関数に対する逆 CDF を任意の精度で多項式近似するアルゴリズム
 - 密度関数是有界なもの限定
 - 1 変数の分布限定
 - 領域を十分な数に分割して近似

Derflinger の主な課題:

領域を多数に分割して近似する → 探索コストがかかる

我々の目標

- 任意の n 変数密度関数 $f(x_1, \dots, x_n)$ が与えられたとき, その分布の逆 CDF の近似モデルを上手に構築する経験則を見つける
- ただし領域の分割はしない (あるいは最小限に抑える)

これまでの研究の経緯:

逆 CDF の近似モデルの候補として, 我々は様々な手法を試みてきた.

- Newton-Padé 近似, 領域を分割した多項式補間の実施, 独自の最良近似アルゴリズム
- しかし, 上記の諸手法は何らかの欠点を抱えていることが判明

試行錯誤の結果, 近年注目されている**重心形式**の一例である **Floater-Hormann 法**という手法が逆 CDF の近似に適切であることが判明した.

近似手法

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

近似手法～基本的な関数近似手法～

多項式近似と有理関数近似

多項式近似: $f(x) \simeq P(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n$

有理関数近似: $f(x) \simeq R(x) = \frac{a_0 + a_1x + a_2x^2 + \cdots + a_mx^m}{1 + b_1x + b_2x^2 + \cdots + b_nx^n}$

局所近似と補間法

局所近似: ある 1 つの点において微分係数の値を一致させる手法

$$f^{(k)}(0) = P^{(k)}(0), \quad 0 \leq k \leq n \text{ (Taylor 近似)}$$

$$f^{(k)}(0) = R^{(k)}(0), \quad 0 \leq k \leq m + n \text{ (Padé 近似)}$$

補間法: 与えられた多数の点 $\{x_i\}$ で値を一致させる手法

$$f(x_i) = P(x_i), \quad \text{for } 0 \leq i \leq n \text{ (e.g. 冪級数補間, Newton 補間)}$$

$$f(x_i) = R(x_i), \quad \text{for } 0 \leq i \leq m + n \text{ (e.g. Newton-Padé 近似, 重心形式)}$$

近似手法～有理関数補間～

有理関数による補間法を採用:

$$f(x) \simeq R(x) = \frac{a_0 + a_1x + a_2x^2 + \dots + a_mx^m}{1 + b_1x + b_2x^2 + \dots + b_nx^n},$$
$$f(x_i) = R(x_i), \quad \text{for } 0 \leq i \leq m + n$$

- 多項式よりも有理関数の方が表現力が豊か. 急峻な変化に強い.
- 有理関数近似の方が, 少ない次数で良い近似を得られる傾向にある
e.g. $\log(1+x) = \frac{x}{1+\frac{1}{2}x} + \mathcal{O}(x^3)$ (Fig.1)
- 1点だけでなく多数の点を使う補間法の方が, 大域的な近似に向いている.




Figure 1: $\log(1+x)$ の局所近似

多項式 VS 有理関数 (同次数)

近似手法～重心形式による有理関数補間～

有理関数補間の中でも性質の良い**重心形式** [3] を用いる:

$$r(x) := \frac{\sum_{i=0}^n \frac{w^{[i]} f(x^{[i]})}{x - x^{[i]}}}{\sum_{i=0}^n \frac{w^{[i]}}{x - x^{[i]}}}$$

重心形式の利点:


- 有理関数補間の最大の弱点である「**到達不能点**」の問題を克服⁵
- さらに、「**不必要な極**」の問題も克服したことで知られる **Floater-Hormann 法** (重心形式の一種, 後述) が安全と判断

⁵ 点 $x^{[i]}$ が到達不能点であるとは, $f(x^{[i]}) = \frac{P(x^{[i]})}{Q(x^{[i]})}$ を満たさない場合をいう.

近似手法～不必要な極の問題～

不必要な極の存在

- 有理関数は、極 (分母がゼロになる点) を持つ場合がある.
- 補間法で得られた有理近似式 $R(x)$ が、(たまたま) 定義域内で、本来 $f(x)$ が持ち得ない **不必要な極** を持つ場合がある.



近似手法～Floater-Hormann 法～

Floater-Hormann 法 (2007)[4]

実軸内で極を持たない重心形式の構築:

$$f(x) \simeq r_d(x) := \frac{\sum_{i=0}^n \frac{w^{[i]} f(x^{[i]})}{x - x^{[i]}}}{\sum_{i=0}^n \frac{w^{[i]}}{x - x^{[i]}}},$$

$$w^{[k]} = (-1)^{k-d} \sum_{i=\max\{0, k-d\}}^{\min\{k, n-d\}} \prod_{j=i, j \neq k}^{i+d} \frac{1}{|x^{[k]} - x^{[j]}|} \quad (0 \leq k \leq d)$$

d : ブレンド次数 (数値的安定性や誤差の収束レートに関係, $0 \leq d \leq n$)

FH 法は「到達不能点」と「不必要な極」の両方を回避出来る。

近似手法～多変数重心形式～

重心形式の有理関数補間は、以下の通り多変数に拡張できる．

被近似関数 $f : \mathbb{R}^N \rightarrow \mathbb{R}$ ，および補間データ $\{(x^{[i]}, f(x^{[i]}))\}_{i \in I}$ に対し，

$$f(x) \simeq r(x) := \sum_{i_1=1}^{n_1} \cdots \sum_{i_N=1}^{n_N} f(x_1^{[i_1]}, \dots, x_N^{[i_N]}) \prod_{j=1}^N \frac{\frac{w_j^{[i_j]}}{x_j - x_j^{[i_j]}}}{\sum_{k=1}^{n_j} \frac{w_j^{[k]}}{x_j - x_j^{[k]}}}$$

ただし， $x = (x_1, \dots, x_N)^T$ ，

$w_j^{[ij]}$ ($1 \leq ij \leq n_j, 1 \leq j \leq N$) : $r(x)$ を決めるパラメータ

近似手法～多変数 Floater-Hormann 法～

多変数 Floater-Hormann 法

$\mathbb{R}^N$ で極を持たない重心形式の構築:

$$f(x) \simeq r_d(x) := \sum_{i_1=1}^{n_1} \cdots \sum_{i_N=1}^{n_N} f(x_1^{[i_1]}, \dots, x_N^{[i_N]}) \prod_{j=1}^N \frac{\frac{w_j^{[i_j]}}{x_j - x_j^{[i_j]}}}{\sum_{k=1}^{n_j} \frac{w_j^{[k]}}{x_j - x_j^{[k]}}}$$

$$w_s^{[k]} := (-1)^{k-d_s} \sum_{i=\max\{0, k-d_s\}}^{\min\{k, n_s-d_s\}} \prod_{j=i, j \neq k}^{i+d_s} \frac{1}{|x_s^{[k]} - x_s^{[j]}|}$$

数値実験: 逆 CDF の近似

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

数値実験～逆 CDF 近似の流れ～

簡単のため、以下では 2 次元以下の場合で考察する。

逆 CDF 近似: 実験の流れ (1 次元の場合)

- 補間点 $\{u^{[i]}\}_{0 \leq i \leq n}$ とブレンド次数 d を決める。
- 「真の値」としての補間データ $\{(u^{[i]}, F_X^{-1}(u^{[i]}))\}_{0 \leq i \leq n}$ を入手する^a
- FH 法を用いて $x = F_X^{-1}(u)$ の有理近似式 $r_d(u)$ を構築:

$$r_d(u) := \frac{\sum_{i=0}^n \frac{w^{[i]} F_X^{-1}(u^{[i]})}{u - u^{[i]}}}{\sum_{i=0}^n \frac{w^{[i]}}{u - u^{[i]}}}, \quad w^{[k]} = (-1)^{k-d} \sum_{i=\max\{0, k-d\}}^{\min\{k, n-d\}} \prod_{j=i, j \neq k}^{i+d} \frac{1}{|u^{[k]} - u^{[j]}|}$$

^a数値積分, 求根アルゴリズムを使って数値的に得る

逆 CDF 近似の流れ (2 次元の場合)

- $x = F_X^{-1}(u)$ について:
 - 1 次元の場合と同じ要領で $F_X^{-1}(u)$ の有理近似式 $r_d(u)$ を構築
- $y = F_{Y|X=x}^{-1}(v)$ について
 - 補間点 $\{(v^{[i]}, x^{[j]})\}_{0 \leq i \leq n_1, 0 \leq j \leq n_2}$ とブレンド次数 $d = (d_1, d_2)$ を決める.
 - 「真の値」としての補間データ $\{((v^{[i]}, x^{[j]}), F_{Y|X=x^{[j]}}^{-1}(v^{[i]}))\}_{0 \leq i \leq n_1, 0 \leq j \leq n_2}$ を入手する
 - FH 法を用いて $F_{Y|X=x}^{-1}(v)$ の有理近似式 $r_d(v, x)$ を構築:

$$r_d(v, x) := \frac{\sum_{i=0}^{n_1} \sum_{j=0}^{n_2} \frac{w_1^{[i]} w_2^{[j]} F_{Y|X=x^{[j]}}^{-1}(v^{[i]})}{(v - v^{[i]})(x - x^{[j]})}}{\sum_{i=0}^{n_1} \sum_{j=0}^{n_2} \frac{w_1^{[i]} w_2^{[j]}}{(v - v^{[i]})(x - x^{[j]})}}, \begin{cases} w_1^{[k]} = (-1)^{k-d_1} \sum_{i=\max\{0, k-d_1\}}^{\min\{k, n_1-d_1\}} \prod_{j=i, j \neq k}^{i+d_1} \frac{1}{|v^{[k]} - v^{[j]}|} \\ w_2^{[k]} = (-1)^{k-d_2} \sum_{i=\max\{0, k-d_2\}}^{\min\{k, n_2-d_2\}} \prod_{j=i, j \neq k}^{i+d_2} \frac{1}{|x^{[k]} - x^{[j]}|} \end{cases}$$

数値実験～逆 CDF 近似～工夫 1: 近似区間の制限, 近似精度の目標～

近似区間の制限

- 逆 CDF は端点 $0, 1$ で発散するため, 端点近似の近似が難しい
- そこで, 近似の範囲を $[10^{-8}, 1 - 10^{-8}]$ とする

↑実用的な準モンテカルロ法 (QMC) の文脈ではこれで十分 (← 第二の研究目標: QMC への応用)⁶

近似精度の目標

- 最大絶対誤差 $\|F^{-1} - r_d\|_{\infty}$ は 10^{-7} オーダーを目指す

↑実用的な準モンテカルロ法 (QMC) の文脈ではこれで十分⁷

⁶QMC を用いた大規模な金融シミュレーションでは, いっぺんに生成する準乱数は高々 $M = 10^7$ 程度であり, 標準的な準乱数列を用いた場合, 端点から $1/2M = 5 \times 10^{-8}$ 以内の極端な値が生成されることは事実上ない.

⁷QMC を用いた大規模な金融シミュレーションでは, いっぺんに生成する準乱数は高々 $M = 10^7$ 程度であり, 標準的な準乱数列を用いた場合, QMC の統計誤差は Koksma-Hlawka の不等式 [5] により一般に $10^{-6} \sim 10^{-5}$ 程度であり, 近似誤差が 10^{-7} オーダーにであれば, 近似誤差は統計誤差に埋もれる.

数値実験～逆 CDF 近似～工夫 2: 変数変換の利用

変数変換



- 逆 CDF が曲率の大きな点を複数持つ場合、提案手法の近似精度が顕著に低下する (経験則)
- そこで、逆 CDF の形状に応じて、適切な変数変換 $u \rightarrow s = s(u)$ を施すことで、関数の曲率が高い領域を引き延ばしてから補間近似式を構築することで、より少ない補間ノード数で高い精度を実現できる

$$\begin{aligned} G(t) &:= F_X^{-1}(s^{-1}(t)) \stackrel{\text{FH}}{\simeq} r_d(t) \\ \Rightarrow F_X^{-1}(u) &= G(s(u)) \stackrel{\text{FH}}{\simeq} r_d(s(u)) \quad (u \in [10^{-8}, 1 - 10^{-8}]) \end{aligned}$$

一般に、 $F_X^{-1}(s^{-1}(t))$ を計算するためには求根アルゴリズムが必要となり計算負荷が高いが、FH 法を適用して $r_d(t)$ を求める際に必要となる補間点 $\{t^{[i]}\}_{i=0,1,\dots,n}$ における値 $\{F_X^{-1}(s^{-1}(t^{[i]}))\}_{i=0,1,\dots,n}$ だけを求根アルゴリズムで求めれば十分であるので、我々の提案手法の計算負荷が高くなることはない。

数値実験～逆 CDF 近似～例:1 次元


$$f_X(x) = \frac{1}{\pi \sqrt{x(1-x)}} (1 + \sin(8\pi x)), \quad x \in (0, 1)$$



数値実験～逆CDF近似～例: 1次元 変数変換による引き延ばし


$$f_X(x) = \frac{1}{\pi\sqrt{x(1-x)}}(1 + \sin(8\pi x)), \quad x \in (0, 1)$$

$x = F_X^{-1}(u)$ のグラフ



$u \rightarrow s(u)$

$x = G(t) = F_X^{-1}(s^{-1}(t))$ のグラフ



※ 変数変換: $u \rightarrow s(u) = \arcsin(2u - 1) + 0.5 \sum_{k=1}^4 \sqrt[3]{u - u_k}$, $u_k = F_X((4k - 1)/16)$

数値実験～逆CDF近似～例:1次元 近似結果

$$f_X(x) = \frac{1}{\pi\sqrt{x(1-x)}}(1 + \sin(8\pi x)), \quad x \in (0, 1)$$

- **ターゲット:** $F_X^{-1}(u) \simeq r_d(s(u))$
($u \in [10^{-8}, 1 - 10^{-8}]$)
- **変数変換マップ** $s(u)$: 端点の特異性と内部の4つのピークを平滑化.

$$s(u) = \arcsin(2u - 1) + 0.5 \sum_{k=1}^4 \sqrt[3]{u - u_k}$$

ただし $u_k = F_X((4k - 1)/16)$

- 補間点: $\{s^{[i]}\}_{0 \leq i \leq n} = \{\frac{i}{n}\}_{0 \leq i \leq n}, \quad n = 320$
- ブレンド次数: $d = 3$

近似式: (小数点以下第 3 位まで)

$$r_d(s) = \frac{0 + \frac{0.002}{s+3.246} + \cdots + \frac{22607.533}{s-2.943}}{\frac{-22607.533}{s+3.265} + \frac{90430.133}{s+3.246} + \cdots + \frac{22607.533}{s-2.943}}$$

最大絶対誤差: $\|F_X^{-1} - r_d\|_\infty < 4.93 \times 10^{-8}$




Figure 2: 絶対誤差





Figure 3: ヒストグラム

数値実験～逆 CDF 近似～例:2 次元混合正規分布 (GMM)

$$f_{X,Y}(x,y) = c \left(e^{-x^2-y^2} + \frac{1}{2} e^{-(x-2)^2-(y-2)^2} \right), \quad (x,y) \in \mathbb{R}^2$$


True PDF $f_{X,Y}(x,y)$




数値実験～逆CDF近似～例:2次元GMM, $F_X^{-1}(u)$, $F_{Y|X=x}(v)$ のグラフ

$$f_{X,Y}(x,y) = c \left(e^{-x^2-y^2} + \frac{1}{2} e^{-(x-2)^2-(y-2)^2} \right), \quad (x,y) \in \mathbb{R}^2$$

$x = F_X^{-1}(u)$ のグラフ



$y = F_{Y|X=x}^{-1}(v)$ のグラフ



数値実験～逆 CDF 近似～例:2 次元 GMM, 近似の結果 for $F_X^{-1}(u)$

$$f_{X,Y}(x,y) = c \left(e^{-x^2-y^2} + \frac{1}{2} e^{-(x-2)^2-(y-2)^2} \right), \quad (x,y) \in \mathbb{R}^2$$

最大絶対誤差: $\|F_X^{-1} - r_d\|_\infty < 8.69 \times 10^{-8}$

- ターゲット: $F_X^{-1}(u) \simeq r_d(s(u))$
($u \in [10^{-8}, 1 - 10^{-8}]$)

- 変数変換マップ $s(u)$:

$$s(u) = \Phi^{-1}(u)$$

- 補間点: $\{s^{[i]}\}_{0 \leq i \leq n} = \{\frac{i}{n}\}_{0 \leq i \leq n}, \quad n = 145$
- ブレンド次数: $d = 3$





Figure 4: 絶対誤差

数値実験～逆 CDF 近似～例:2 次元 GMM, $F_{Y|X=x}^{-1}(v)$ のグラフ～

$$f_{X,Y}(x,y) = c \left(e^{-x^2-y^2} + \frac{1}{2} e^{-(x-2)^2-(y-2)^2} \right), \quad (x,y) \in \mathbb{R}^2$$

$y = F_{Y|X=x}^{-1}(v)$ のグラフ

Target Function



数値実験～逆CDF近似～例:2次元GMM, 近似結果 for $F_{Y|X=x}^{-1}(v)$

$$f_{X,Y}(x,y) = c \left(e^{-x^2-y^2} + \frac{1}{2} e^{-(x-2)^2-(y-2)^2} \right), \quad (x,y) \in \mathbb{R}^2$$

最大絶対誤差: $\|F_{Y|X}^{-1} - r_d\|_\infty < 7.91 \times 10^{-8}$

- ターゲット: $F_{Y|X=x}^{-1}(v) \simeq r_d(s(v), t(x))$
 $((v,x) \in [10^{-8}, 1 - 10^{-8}] \times \mathbb{R})$

- 変数変換マップ $s(v), t(x)$:

$$s(v) = \Phi^{-1}(v), \quad t(x) = \frac{2}{1 + e^{-0.5(x-1.173)}}$$

- 補間点:

- $\{s^{[i]}\}_{0 \leq i \leq n_1} = \left\{\frac{i}{n_1}\right\}_{0 \leq i \leq n_1}, \quad n_1 = 150$
- $\{t^{[i]}\}_{0 \leq i \leq n_2} = \left\{\frac{i}{n_2}\right\}_{0 \leq i \leq n_2}, \quad n_2 = 210$

- ブレンド次数: $d = (5, 5)$




Figure 5: 絶対誤差





Figure 6: ヒストグラム

数値実験～逆 CDF 近似～例:2 次元モヒカン分布

$$f_{X,Y}(x,y) = c \cdot \frac{\exp(-0.2x)}{(1+x^2+(y-\log(1+x))^2)^2}, \quad (x,y) \in [0,20] \times [-5,10]$$


True PDF $f_{X,Y}(x,y)$



数値実験～逆 CDF 近似～例:2 次元モヒカン分布, $F_X^{-1}(u)$, $F_{Y|X=x}^{-1}(v)$ のグラフ


$$f_{X,Y}(x,y) = c \cdot \frac{\exp(-0.2x)}{(1+x^2+(y-\log(1+x))^2)^2}, \quad (x,y) \in [0,20] \times [-5,10]$$

$x = F_X^{-1}(u)$ のグラフ



$y = F_{Y|X=x}^{-1}(v)$ のグラフ

$$G(v,x) = F_{Y|X=x}^{-1}(v)$$



数値実験～逆CDF近似～例:2次元モヒカン分布, 近似の結果 for $F_X^{-1}(u)$

$$f_{X,Y}(x,y) = c \cdot \frac{\exp(-0.2x)}{(1+x^2+(y-\log(1+x))^2)^2}$$

- ターゲット: $F_X^{-1}(u) \simeq r_d(s(u))$
($u \in [10^{-8}, 1 - 10^{-8}]$)
- 変数変換マップ $s(u)$:

$$s(u) = \log \frac{u}{1-u}$$

- 補間点: $\{s^{[i]}\}_{0 \leq i \leq n} = \{\frac{i}{n}\}_{0 \leq i \leq n}, \quad n = 70$
- ブレンド次数: $d = 5$

最大絶対誤差: $\|F_X^{-1} - r_d\|_{\infty} < 2.23 \times 10^{-7}$




Figure 7: 絶対誤差

数値実験～逆CDF近似～例:2次元モヒカン分布, 近似結果 for $F_{Y|X=x}^{-1}(v)$

$$f_{X,Y}(x,y) = c \cdot \frac{\exp(-0.2x)}{(1+x^2+(y-\log(1+x))^2)^2}$$

- ターゲット: $F_{Y|X=x}^{-1}(v) \simeq r_d(s(v), t(x))$
 $((v, x) \in [10^{-8}, 1 - 10^{-8}] \times [0, 20])$

- 変数変換マップ $s(v), t(x)$:

$$s(v) = \log \frac{v}{1-v}, \quad t(x) = \log(0.5 + x)$$

- 補間点:

- $\{s^{[i]}\}_{0 \leq i \leq n_1} = \left\{\frac{i}{n_1}\right\}_{0 \leq i \leq n_1}, \quad n_1 = 200$
- $\{t^{[i]}\}_{0 \leq i \leq n_2} = \left\{\frac{i}{n_2}\right\}_{0 \leq i \leq n_2}, \quad n_2 = 200$

- ブレンド次数: $d = (3, 3)$

最大絶対誤差: $\|F_{Y|X}^{-1} - r_d\|_{\infty} < 2.02 \times 10^{-7}$




Figure 8: 絶対誤差




Figure 9: ヒストグラム

目次

数値実験: 求根アルゴリズム VS 近似モデル

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

数値実験～求根アルゴリズム VS 近似モデル～

求根アルゴリズムによる逆関数法

一様乱数 u, v に対し方程式 $F_X(x) = u$,
 $F_{Y|X=x}(y) = v$ を x, y について数値的に解く
→ アルゴリズムの収束, PDF の数値積分の
計算コスト
→ n 変数の場合, n 個の条件付き CDF につ
いて諸計算を行う → 計算コストが莫大

近似モデルによる逆関数法

事前に構成した有理近似式の単純な四則演算
を評価するのみ.^a

^a補間データ生成時に 1 度だけ求根・数値積分は
行う.

10⁴ 個の乱数生成時間の比較

対象分布	求根	近似モデル
1 次元	582.100 秒	0.063 秒
混合正規	896.469 秒	0.108 秒
モヒカン	3013.445 秒	0.085 秒

※精度水準は絶対誤差を 10^{-7} オーダーに統一
※求根アルゴリズムは Brent 法を使用

数値実験:QMC の収束性の検証

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験:QMC の収束性の検証**
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

数値実験～QMC の収束性の検証～


【検証内容】 モヒカン分布に従う確率変数 (X, Y) の期待値 $E[XY]$ に焦点を当て、Scrambled Sobol' 列 [6] を用いて QMC を実施:

- Scrambled Sobol' 列による QMC では,
 $|E[XY] - \frac{1}{M} \sum_{m=1}^M x_m y_m| = \mathcal{O}(M^{-3/2}) \sim \mathcal{O}(M^{-1})$
が知られている
- 近似モデルがこの誤差の収束レートに影響を与えないことを実証したい:
近似モデルによる QMC 誤差: $(x_m, y_m) = (r_d(u_m), r_d(v_m, r_d(u_m)))$ としたもの
真の QMC 誤差: $(x_m, y_m) = (F_X^{-1}(u_m), F_{Y|X=F_X^{-1}(u_m)}^{-1}(v_m))$ としたもの⁸
- そこで、上記の 2 通りの (x_m, y_m) について、 $|E[XY] - \frac{1}{M} \sum_{m=1}^M x_m y_m|$ を $M = 2^{10}$ から 2^{24} にわたって実測値を数値計算

⁸ただし、 $(F_X^{-1}(u_m), F_{Y|X=F_X^{-1}(u_m)}^{-1}(v_m))$ は Brent 法を用いて得られた数値解を真の値とみなす

数値実験～QMC の収束性の検証～実験結果

× : 近似モデル, ● : Brent 法, (▲ : 近似モデルでの通常の MC)



- 収束レートは $O(M^{-1})$ を上回る
- 誤差は近似モデルと真の値 (Brent 法) でほぼ一致→近似誤差が全体の誤差を阻害していない

結論・今後の展望

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

まとめと今後の課題

【まとめ】

- **成果 1:** Floater-Hormann 法に基づく重心有理補間を用いることで、多次元・複雑な分布に対しても極を持たない安定した逆 CDF の近似手法を構築できた.
- **成果 2:** 適切な変数変換との組み合わせにより, 目標精度 (10^{-7} オーダー) を達成した.
- **成果 3:** 実用的な QMC においても, 近似モデル由来の誤差が収束性を阻害せず, 本来の QMC の高いパフォーマンスを引き出せることを実証した.

【今後の課題】

- 本研究では, 逆 CDF を平滑化するための変数変換 $u \rightarrow s(u)$ は, 分布の形状に応じて試行錯誤を行い決定しているが, 今後はこの部分を自動化したい.

ご清聴ありがとうございました.

付録

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献

付録～ルンゲ現象～

● 所与の関数に対し, 近似関数が区間の両端付近で暴れる現象を**ルンゲ現象**と呼ぶ
補間点が等間隔の場合の FH 型のルンゲ現象の大きさを表す定数を Λ_{n_1, n_2} とすると, Bos[7] の結果を用いると,

$$\Lambda_{n_1, n_2} \leq 2^{d_1 + d_2 - 2} (2 + \log n_1) (2 + \log n_2). \quad (1)$$

ここで, 関数 f が十分に滑らかであれば, 以下が成立する. (Jing[8])

$$\|f - r_{d_1, d_2}\|_{\infty} \leq C_1 h_1^{d_1+1} + C_2 h_2^{d_2+1} + C_3 h_1^{d_1+1} h_2^{d_2+1}. \quad (2)$$

ここで h_1, h_2 は補間点の間隔の最大値を表す. (2) より, ブレンド次数 d_1, d_2 を大きくすると f と r_{d_1, d_2} の絶対誤差は 0 に近づくが, (1) よりルンゲ現象が大きくなってしまふことがわかる. よって

近似精度とルンゲ現象の抑制の両方を考慮し, ブレンド次数 d_1, d_2 は比較的小さい値を選ぶ.

付録：Wichura (1988) PPND16 の逆CDF 近似係数

係数	値
a_0	3.3871328727963666080
a_1	$1.3314166789178437745 \times 10^2$
a_2	$1.9715909503065514427 \times 10^3$
a_3	$1.3731693765509461125 \times 10^4$
a_4	$4.5921953931549871457 \times 10^4$
a_5	$6.7265770927008700853 \times 10^4$
a_6	$3.3430575583588128105 \times 10^4$
a_7	$2.5090809287301226727 \times 10^3$
b_1	$4.2313330701600911252 \times 10^1$
b_2	$6.8718700749205790830 \times 10^2$
b_3	$5.3941960214247511077 \times 10^3$
b_4	$2.1213794301586595867 \times 10^4$
b_5	$3.9307895800092710610 \times 10^4$
b_6	$2.8729085735721942674 \times 10^4$
b_7	$5.2264952788528545610 \times 10^3$

係数	値
c_0	1.42343711074968357734
c_1	4.63033784615654529590
c_2	5.76949722146069140550
c_3	3.64784832476320460504
c_4	1.27045825245236838258
c_5	$2.41780725177450611770 \times 10^{-1}$
c_6	$2.27238449892691845833 \times 10^{-2}$
c_7	$7.74545014278341407640 \times 10^{-4}$
d_1	2.05319162663775882187
d_2	1.67638483018380384940
d_3	$6.89767334985100004550 \times 10^{-1}$
d_4	$1.48103976427480074590 \times 10^{-1}$
d_5	$1.51986665636164571966 \times 10^{-2}$
d_6	$5.47593808499534494600 \times 10^{-4}$
d_7	$1.05075007164441684324 \times 10^{-9}$

係数	値
e_0	6.65790464350110377720
e_1	5.46378491116411436990
e_2	1.78482653991729133580
e_3	$2.96560571828504891230 \times 10^{-1}$
e_4	$2.65321895265761230930 \times 10^{-2}$
e_5	$1.24266094738807843860 \times 10^{-3}$
e_6	$2.71155556874348757815 \times 10^{-5}$
e_7	$2.01033439929228813265 \times 10^{-7}$
f_1	$5.99832206555887937690 \times 10^{-1}$
f_2	$1.36929880922735805310 \times 10^{-1}$
f_3	$1.48753612908506148525 \times 10^{-2}$
f_4	$7.86869131145613259100 \times 10^{-4}$
f_5	$1.84631831751005468180 \times 10^{-5}$
f_6	$1.42151175831644588870 \times 10^{-7}$
f_7	$2.04426310338993978564 \times 10^{-15}$

出典：Wichura (1988), Algorithm AS 241, PPND16

付録～Acklam の逆 CDF 近似係数～

$$a_1 = -3.969683028665376 \times 10^1,$$

$$a_2 = 2.209460984245205 \times 10^2,$$

$$a_3 = -2.759285104469687 \times 10^2,$$

$$a_4 = 1.383577518672690 \times 10^2,$$

$$a_5 = -3.066479806614716 \times 10^1,$$

$$a_6 = 2.506628277459239 \times 10^0,$$

$$b_1 = -5.447609879822406 \times 10^1,$$

$$b_2 = 1.615858368580409 \times 10^2,$$

$$b_3 = -1.556989798598866 \times 10^2,$$

$$b_4 = 6.680131188771972 \times 10^1,$$

$$b_5 = -1.328068155288572 \times 10^1$$

$$c_1 = -7.784894002430293 \times 10^{-3}$$

$$c_2 = -3.223964580411365 \times 10^{-1}$$

$$c_3 = -2.400758277161838 \times 10^0$$

$$c_4 = -2.549732539343734 \times 10^0$$

$$c_5 = 4.374664141464968 \times 10^0$$

$$c_6 = 2.938163982698783 \times 10^0$$

$$d_1 = 7.784695709041462 \times 10^{-3}$$

$$d_2 = 3.224671290700398 \times 10^{-1}$$

$$d_3 = 2.445134137142996 \times 10^0$$

$$d_4 = 3.754408661907416 \times 10^0$$

参考文献

- ① はじめに
- ② 導入
- ③ 近似手法
- ④ 数値実験: 逆 CDF の近似
- ⑤ 数値実験: 求根アルゴリズム VS 近似モデル
- ⑥ 数値実験: QMC の収束性の検証
- ⑦ 結論・今後の展望
- ⑧ 付録
- ⑨ 参考文献



P.J.Acklam.

<http://home.online.no/~pjacklam/notes/invnorm>.



Gerhard Derflinger, Wolfgang Hörmann, and Josef Leydold.

Random variate generation by numerical inversion when only the density is known.
WorkingPaper 78, 2008.

Earlier version.



Kai Hormann.

Barycentric Interpolation.

In Gregory E. Fasshauer and Larry L. Schumaker, editors, *Approximation Theory XIV: San Antonio 2013*, volume 83, pages 197–218. Springer International Publishing, Cham, 2014.



Michael S. Floater and Kai Hormann.

Barycentric rational interpolation with no poles and high rates of approximation.
Numerische Mathematik, 2007.



Niederreiter Harald.

Random number generation and quasi-monte carlo methods.
63, 01 1992.



Art B. Owen.

Scrambled net variance for integrals of smooth functions.
The Annals of Statistics, 25(4):1541–1562, 1997.



Len Bos, Stefano De Marchi, Kai Hormann, and Georges Klein.

On the Lebesgue constant of barycentric rational interpolation at equidistant nodes.
Numerische Mathematik, 121(3):461–471, July 2012.



Ke Jing and Ning Kang.

A Convergent Family of Bivariate Floater-Hormann Rational Interpolants.
Computational Methods and Function Theory, 21(2):271–296, June 2021.